기계 학습 기반 실내 음원의 위치 탐색

한 승 재[1,2] · 김 상 현[1,2] · 서 지 원[1,2]
[1]연세대학교 글로벌융합공학부
[2]연세대학교 글로벌융합기술원

Machine Learning Based Sound Source Localization in the Indoor Environment

Seungjae Han[1,2] · Sanghyun Kim[1,2] · Jiwon Seo[1,2]
[1]School of Integrated Technology, Yonsei University
[2]Yonsei Institute of Convergence Technology, Yonsei University

Abstract

In this paper, we implemented a machine learning approach to find the location of sound source in the indoor environment using the sounds acquired by two microphones. The experiment was conducted in the 'L' shape indoor hall. Two microphones and one speaker were located at both ends. Two different machine learning models were tested, including classification and regression methods. The implemented method demonstrated about 20 cm accuracy.

I. 서 론

최근 드론, 무인 로봇과 관련한 다양한 연구가 활발하게 진행되고 있다. 특히, 로봇과 인간의 상호작용에서 소리는 매우 중요하다. Sound source localization은 소리를 듣고 그 소리가 발생한 지점의 방향을 알아내는 것이다. 인간의 경우 귀의 모양, 몸의 형태 정보 등을 종합하여 어떠한 각도와 높이에서 소리가 발생했는지를 분별할 수 있다 [1]. 만약 소리를 듣고 이 소리가 발생한 지점의 위치를 정확하게 판단할 수 있다면 많은 곳에서 응용할 수 있다. 예를 들어, 화재나 사고 상황에서 상황을 빠르게 파악할 수 있고 실내 순찰 로봇, 안내 로봇에도 사용할 수 있다 [2-4].

장애물이 없고 탁 트인 외부에 비해 실내 환경에서는 소리의 반사, 간섭으로 인해 소리가 발생한 지점의 위치르 추정하는 것이 쉽지 않아서 관련 연구가 진행되고 있다 [5, 6]. 또한, sound source localization에 기계 학습 기법을 적용하는 연구도 활발히 진행되고 있다 [5-8]. 그러나 단순히 직육면체 모양의 방이 아닌 복잡한 구조를 가진 건물의 실내 환경에서의 sound source localization은 정확하게 다뤄진 바가 없다.

본 연구에서는 그림 1과 같은 ‘ㄱ’ 모양의 실내 복도 양 끝에 스피커와 마이크가 있는 상황에서 기계 학습 기법을 사용하여 마이크로 들어온 소리로부터 스피커의 위치를 높은 정확도로 탐색하는 것을 목표로 하였다. 그림 1에서 파란 사각형에 두 개의 마이크가 있고, 스피커는 12개의 붉은 점들이 위치한 직사각형 내에서 실험을 진행하였다. 붉은 점들이 위치한 직사각형은 가로 90cm, 세로 180cm이다.

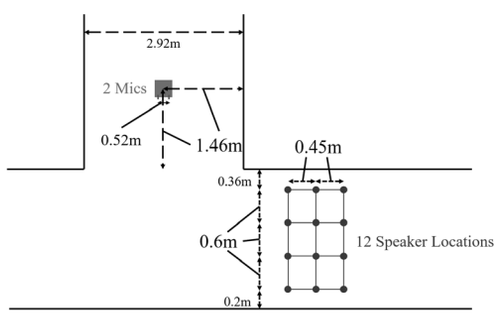

그림 1. 실험환경

II. 기계 학습 방법

데이터를 수집하기 위하여 그림 1의 붉은 사각형 안에서 3*4 구조로 12개의 지점에 스피커를 이동하여 위치시킨 후, 일정한 간격으로 소리를 발생시켰다. 그리고 파란 지점에 위치한 두 개의 마이크 사이에 0.52m 간격을 두고 스피커에서 발생한 소리를 받도록 하였다. 이렇게 얻은 데이터들을 기계 학습을 위한 데이터로 사용했다.

사람이 sound source localization을 할 때는 두 귀에 들어오는 소리의 시간 차이와 크기 차이를 사용한다고 알려져 있다 [9]. 즉, 두 마이크에서 얻어진 두 소리의 시간 차이와 크기 차이를 바탕으로 음원의 위치 탐색이 가능할 것이다.

본 논문에서는 두 가지 방법으로 소리 신호를 기계 학습에 사용하였다. 첫 번째는 두 소리 신호에서부터 이벤트가 발생 시

간 차이와 소리의 크기 차이를 얻어내어 이를 학습에 사용하는 방법이고, 두 번째는 얻어진 소리 신호 자체를 학습에 사용하는 것이다.

III. Classification 모델 적용

첫 번째 모델은 Softmax classification을 사용하였다. 12개의 지점에 1번부터 12번으로 label을 붙여 학습을 시키고, 새로운 데이터가 들어오면 1부터 12중에 가장 가능성이 큰 위치를 출력하도록 하였다. 모델은 1번부터 12번 중 스피커가 존재할 확률을 계산하여 출력하고, 이에 argmax를 취하면 확률이 제일 높은 label을 얻을 수 있다.

입력 데이터는 두 소리 데이터로부터 얻어지는 4개의 feature (시간 차이, 크기 비율, 왼쪽에 들어오는 소리의 크기, 오른쪽에 들어오는 소리의 크기)를 가지는 480행의 행렬이다. 480행의 데이터에서 training set과 validation set을 90%, 10%로 무작위로 나누었기 때문에 실제로 학습에 사용된 데이터는 각각 432행, 48행이다. 모델 내에서 입력 데이터와 출력 데이터 사이는 4×12 배열의 weight이 사용되었다.

Test set에 대한 결과는 그림 2와 같다. 1부터 12지점들 사이에 붉은색 동그라미로 표현된 8개의 지점을 선택하여 학습에 사용되지 않은 데이터를 만들었다. 이를 모델에 입력하여 얻어진 결과에서 1번부터 12번까지 확률이 높은 곳일수록 진한 파란색으로 표시하였다. 실제 위치인 붉은 동그라미와 인접한 곳에 가장 확률이 높다고 표현된 경우는 8번 중 4번이며 그 외의 경우에는 실제와 전혀 다른 위치가 추정되었다.

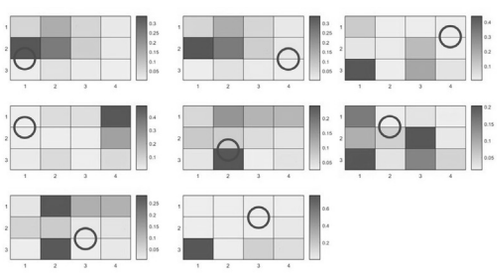

그림 2. 첫 번째 모델의 결과

이렇게 잘못된 위치가 추정된 세 가지 이유를 아래와 같이 정리하였다.

1) Classification model이 아닌 regression model이 이 주제와 실험환경에서 적합하다.

그림 3은 validation set에 대한 결과 중 특징을 가지고 있는 일부를 정리한 것이다. 그림 3의 A는 모델이 음원의 위치를 정확하게 맞추었지만, 정확한 위치가 아닌 다른 지점에서도 매우 유사한 존재 확률을 보였다. B와 C는 실제 정확한 위치가 아니라 그와 인접한 양쪽 두 지점을 정확한 위치라고 추정하였다.

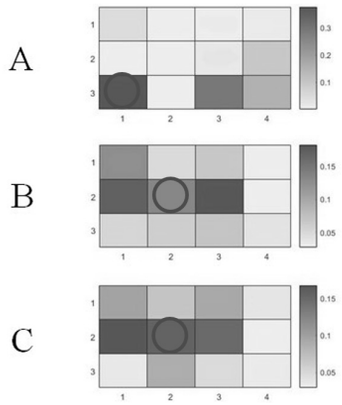

그림 3. 첫 번째 모델의 문제점

1번부터 12번으로 나누어 놓은 위치에서 인접한 지점들일수록 입력 데이터가 유사할 것인데 classification 모델을 사용할 경우 이를 고려할 수 없다. 또한 모델의 정확성을 평가할 때에도 classification보다 regression이 적합하다고 할 수 있다.

2) 모델이 너무 단순하다.

첫 번째 모델의 경우, 입력과 출력 데이터 사이가 단 하나의 행렬로 되어 있어 선형적으로 결합되어 있다. 모델이 단순하여 여러 번, 오랫동안 학습을 진행하여도 validation set에서부터 구한 정확도가 충분히 높지 않았다. 입력과 출력 사이의 관계를 더욱 정확하게 학습할 수 있도록 개선된 모델이 필요하며, 이를 위해 4장에서 기술할 두 번째 모델에서는 입력과 출력 데이터 사이에 layer를 추가하고 비선형 함수를 활성화 함수로 사용했다.

3) 소리 신호 전체를 학습에 사용하는 것이 적합하다.

두 소리 신호로부터 얻어지는 4개의 feature만을 학습에 사용하는 것은 입력 데이터의 오차에 대한 안정성이 떨어지는 등의 문제가 있다. 그렇기 때문에 4장에서 기술할 두 번째 모델에서는 4개의 feature가 아니라 전체 소리 데이터를 학습에 사용하였다.

IV. Regression 모델 적용

Classification을 사용한 첫 번째 모델의 단점을 개선하고자 두 번째 모델에서는 regression을 사용하였다. 1번부터 12번의 label이 아닌 두 마이크의 중점으로부터의 상대적인 직교 좌표를 사용하였다. 또한, 두 마이크로 얻어진 두 소리 신호를 붙여 한 행당 264,600개의 열을 가지고 있는 데이터 전체를 학습에 사용하

였다. 사용한 모델의 구조는 그림 4와 같다. 파란색은 dense layer이고 주황색은 rectified layer unit(ReLU)이고 회색이 출력값이다.

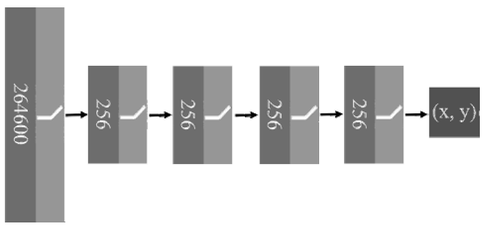

그림 4. Regression 모델의 구조

입력 데이터 한 행당 264,600개의 데이터를 가지고 있는데 이를 첫 번째 dense layer를 통과시켜 256개로 줄인다. 이후 3번의 dense layer를 통과시키고 마지막 dense layer에서 2개의 값을 출력게 되는데, 마지막 출력값 2개는 마이크의 위치를 원점으로 한 직교 좌표에서 음원의 위치를 의미한다. 모든 dense layer에는 ReLU를 사용하여 비선형성을 추가시켰다. 5개의 dense layer는 선형으로 쌓인(sequential) 구조이다.

V. 실험 결과

실제 정확한 음원의 위치와 모델이 예상한 위치의 차이를 유클리드 거리를 통해 계산하여 모델의 정확도를 분석하였다. 그림 5는 음원 위치 탐색 결과의 예시이다. 실내 복도의 구조는 검정 선으로 표시되어 있고, 3개의 파란색 동그라미가 실제 스피커의 위치, 3개의 붉은색 동그라미가 두 번째 모델이 예측한 스피커의 위치이다. Test set에 있는 48개 데이터에 대한 정확도의 평균값은 23.38cm였다.

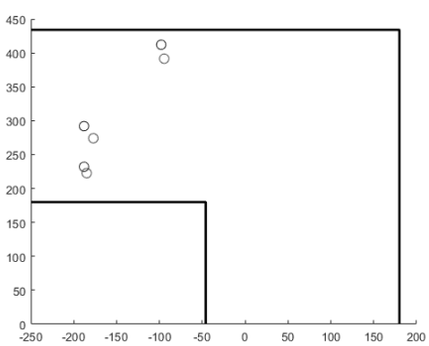

그림 5. 음원의 위치 탐색 결과 예시

VI. 결론

본 논문에서는 마이크로 들어온 소리 신호를 이용하여, ‘ㄱ’ 모양의 실내 복도에서 소리가 발생한 지점의 위치를 약 20cm의 정확도로 알아낼 수 있는 기계 학습 모델을 개발하였다.

감사의 글

이 논문은 2019년도 정부(교육부)의 재원으로 한국과학창의재단(2019년도 학부생 연구프로그램)의 지원을 받아 수행된 연구임.

참고문헌

[1] A. Alves-Pinto, A. R. Palmer, and E. A. Lopez-Poveda, “Perception and coding of high-frequency spectral notches: potential implications for sound localization,” Frontiers in neuroscience, vol. 8, no. 112, May 2014.

[2] C. Rascon and I. Meza, “Localization of sound sources in robotics: A review,” Robotics and Autonomous Systems, vol. 96, pp. 184–210, 2017.

[3] H. Kar, A. Agarwal, and S. Banerjee, "Detection of Audio Source Direction Using an Autonomous Robot", 2006

[4] H.-D. Kim, J.-S. Choi, and C.-H. Lee, “Reliable detection of sound's direction for human robot interaction,” IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), vol. 3, pp. 2411–2416, 2004.

[5] E. L. Ferguson, S. B. Williams, and C. T. Jin, “Sound Source Localization in a Multipath Environment Using Convolutional Neural Networks,” 2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), 2018.

[6] Y. Sun, J. Chen, C. Yuen, and S. Rahardja, “Indoor Sound Source Localization With Probabilistic Neural Network,” IEEE Transactions on Industrial Electronics, vol. 65, no. 8, pp. 6403–6413, Dec. 2017.

[7] Z.-Q. Wang, X. Zhang, and D. L. Wang, “Robust Speaker Localization Guided by Deep Learning-Based Time-Frequency Masking,” IEEE/ACM Transactions on Audio, Speech, and Language Processing , vol. 27, no. 1, pp. 178–188, Oct. 2018.

[8] J. M. Vera-Diaz, D. Pizarro, and J. Macias-Guarasa, “End-to-End Acoustic Localization Using Deep Learning: From Audio Signals to Source Position Coordinates,” Sensors (Basel), vol. 18, no. 10, Oct. 2018.

[9] Z. Cheng, H. Ruimin, T. Weiping, W. Xiaochen, and G. Li, “Binaural Moving Sound Source Localization by Joint Estimation of ITD and ILD,” Audio Engineering Society Convention 130, May 2011.